

情報数理科学III

Assignment 2: Machine Learning on Datasets Without Features

学際科学科総合情報学コース 3 年 08-262024

南條佑太

1. 使用したデータセットについて

今回は、明示的な特徴量を持たないデータセットとして文章のデータの Livedoor ニュースコーパスを選んだ。このデータセットは株式会社ロンウィットが公開している日本語のテキストコーパスであり、ニュースサイト livedoor ニュースにて実際に配信された記事のテキストデータを収集したものである。総記事数は約 7,300 件にのぼり、IT ライフハックやスポーツウォッチなどの多様なジャンルの 9 つのニュースカテゴリに分類されている。

このデータセットの課題は、与えられた記事がどのカテゴリの記事かを分類することで、カテゴリは独女通信、IT ライフハック、家電チャンネル、livedoor HOMME、MOVIE ENTER、Peachy、エスマックス、Sports Watch、トピックニュースの 9 つである。これらのカテゴリは近いものも遠いものも含まれていて、例えば IT ライフハックと家電チャンネルはどちらもネット系の内容なので含まれている単語が似通っているので分類ミスがこれらで起こる可能性が高いと思われる。

学習モデルにデータを入れる前に、生のテキストに対して前処理を行う必要がある。まず日本語の文章は単語間で区切りがないので、形態素解析器 (fugashi) および辞書 (ipadic) を用いてテキストを、意味を持つ最小の構成単位に分割した。次に、出現頻度の高い単語群を抽出し、それぞれに一意の整数 ID を割り当てた。出現頻度が極端に低い単語は未知語として扱うことで、語彙数の爆発を防ぎつつ計算効率を確保した。そしてニュース記事の長さは可変であるため、モデルへの入力次元 (テンソルの形状) を固定する目的で、最大系列長を 256 単語に設定した。これより短い記事にはゼロ埋めを施し、長い記事は 256 単語でトランケーションを行うことでミニバッチ処理が可能な形式へと整えた。

2. 使用した手法

今回はテキストデータから記事のカテゴリを決定づける特徴表現を自律的に抽出するため、1 次元畳み込みニューラルネットワークを構築した。まず入力されたデ

ータは Embedding 層を通過する。ここでは、前処理で得られた離散的な単語 ID の配列を受け取り、各単語を連続値の密ベクトルに変換することで、ニューラルネットワークが単語同士の意味的な関係を計算できる状態にする。次に、Conv1d 層において、連続する単語を 1 つのウィンドウとして捉え、テキスト全体をスライドさせながら畳み込み演算を行う。これにより各カテゴリに特有の特徴的な言い回しやキーワードを局所的な特徴マップとして抽出する。なおこの際の活性化関数には ReLU を用いた。

続いて Global Max Pooling 層において、畳み込み層で抽出された特徴マップの系列全体から最大値のみを取り出す。これにより、その特徴的なフレーズが記事のどこにあったかという位置情報を棄却し、記事内に存在したかどうかという情報のみを固定長の特徴ベクトルとして圧縮する。さらに、このプーリング後の特徴ベクトルは Dropout 層を通過し、学習時に指定した確率でランダムにニューロンが無効化される。これにより、特定の単語への過剰な依存を防ぎ、未知のデータに対する汎化性能を向上させている。最後に、抽出された特徴ベクトルは Linear 層に渡され、線形変換によって 9 つのニュースカテゴリそれぞれに属する確率として出力される。

3. パラメータのチューニング

モデルのパラメータ数と Dropout、および特徴抽出のカーネルサイズが分類精度に与える影響を評価するため、以下の 4 つの設定で比較実験を行った。すべての設定において学習回数は 10 エポック、バッチサイズは 64、最適化手法は Adam（学習率 0.001）で統一している。1 つ目の設定 A は単語埋め込み次元数が 128、フィルタ数が 256、カーネルサイズが 3、Dropout 率が 0.5 で、2 つ目の設定 B は単語埋め込み次元数が 512、フィルタ数が 256、カーネルサイズが 3、Dropout 率が 0 で、3 つ目の設定 C は単語埋め込み次元数が 128、フィルタ数が 256、カーネルサイズが 5、Dropout 率が 0.5 で、4 つ目の設定 D は単語埋め込み次元数が 256、フィルタ数が 512、カーネルサイズが 3、Dropout 率が 0.6 とした。

4. 結果と考察




図1 それぞれのモデルにおける、学習回数とテストデータに対する正解率

上記の4つモデルで学習させた結果、図1のようになった。最高の正解率は設定Dの94.85%になったが、全てのモデルで4回ほど学習すると正解率が90%を超える結果となった。それぞれのモデルでの結果を比較して考察していく。

まず全てのモデルにおいて学習回数が少ないうちは精度が急に上がっていて、学習回数が多くなると頭打ちになって正解率は細かく上下をしている。これは学習の初期段階において、モデルが各カテゴリを決定づける強力で分かりやすい特徴を急速に獲得し、誤差関数の谷を大きく下ったためである。一方、学習回数が進むにつれて精度が頭打ちとなり微小な上下動を繰り返すようになるのは、モデルがすでに最適解の付近に到達していることと、ミニバッチ学習による勾配計算のノイズとDropoutのランダム性によって、最適解の周辺でパラメータが細かく振動しているためと考えられる。

設定Bのグラフを見るとすぐに正解率が高くなっていることがわかる。これは単語埋め込み次元数が512と大きく設定されていて、過学習を抑制するdropoutが0と無効化されているので、学習を妨げる制約がないので、モデルが訓練データを急速に学習できているためだと考えられる。逆に学習回数が大きくなると訓練データにフィットしすぎて過学習を引き起こすと予想されたが、今回の10回の間では少し精度が下がるだけで明らかな過学習は起こらなかったと思われる。

設定AとCのグラフを比較すると学習回数が2から5程度の時だけ少しだけ正解率が高いがあとはほとんど同じである。この二つのモデルはカーネルサイズだけが異なっている。カーネルサイズが大きいことで、学習が少ないうちでもより広い文脈を処理できるのでこのような違いが生じたのだと考えられる。

これらに対して、最も高い正解率の 94.85 を記録したのが設定 D である。設定 D は単語埋め込み次元数を 256、フィルタ数を 512 と、設定 A よりも大幅に拡大し、モデルの表現力を大きくしている。通常であれば設定 B のように過学習を引き起こす設定だが、Dropout 率を 0.6 という他より強い値に設定することで、他のモデルより強い正則化をかけている。この高い表現力と強い正則化が機能したことで、過学習を抑え込みながら未知のデータに対する高い汎化性能を獲得できたと考えられる。

最も正解率が高かった設定 D において、テストデータへの分類の結果と正しいカテゴリを表にして、表 1 にまとめた。表 1 で対角線上にあるのが正しく分類されたケースで、それ以外が間違えたものである。表 1 を見るとほとんどが対角線上にあることがわかる。

具体的に誤分類の傾向を分析すると、第 1 章で予想した IT ライフハックと家電チャンネルの間の分類ミスは数件 (IT→家電が 2 件、家電→IT が 1 件) に留まっており、人にとって類似していると思われるジャンルであってもモデルが文脈の違いを高精度に識別できていることが確認できた。一方で、最も顕著な誤分類は家電チャンネルの正解記事を独女通信と予測したケース (8 件) であった。このように、人間が思うカテゴリの近さと、カテゴリに含まれる記事に書かれている語彙やフレーズの近さには違いがあることがわかった。

今回は計算を Google Colab 上で CPU を使って行ったので、実行にかなり時間がかかるので、パラメータをより多く細かく変化させることはしなかったのが最適なパラメータの設定を求めることはできなかった。しかし少ない学習回数やモデルの比較で正解率が 94.85% とかなり高い正解率を出すことができた。

5. AI (Gemini) の使用について

主に PyTorch を用いたネットワークの構築手法や、各ハイパーパラメータがモデルに与える数理的な影響を理解するための壁打ち相手として Gemini を使用した。最適な回答を得るために、プロンプトはイテレーションを行った。例えば、1D-CNN のネットワークアーキテクチャの説明を求める際、初期プロンプトでは CNN について詳しく教えてと入力したが、テンソルの数式展開などレポートの分量に対して過剰に詳細な出力が得られた。そこで、もう一度手法を簡潔に書いて。あんまり詳しくなくても大丈夫だからとプロンプトを修正し、各層の直感的な役割のみを抽出させるよう出力をコントロールした。




表1 最適なモデル（設定 D）でのテストデータへの予測の結果