

統計学実習最終自由課題

所属：理科一類 3 7 組

学籍番号：J4-241094

南條佑太

1. Introduction



本講義で学習した統計的予測手法を使用するのに適当なデータを探し、WEB 上でのデータで十分なデータ数があり複数のパラメータが存在し欠損値がなく取り扱いやすいものを選んだ。今回使用したカリフォルニア住宅価格データセットはサンプル数が 20640 でパラメータ数は 8 個となっている。いくつかの分析手法を用いて、パラメータから住宅価格の中央値をより良く予測するようなモデルを構築することを目的として、解析を行なった。

2. Methods








今回使用したデータセット、カリフォルニア住宅価格データセットは Python の機械学習ライブラリ scikit-learn を通じて取得し、その出典は 1990 年の米国国勢調査となっている。データの中身は、ブロックグループ内の住宅価格の中央値と、所得、築年数、部屋数、寝室数、人口、世帯人数、緯度、経度である。

解析方法として、まずデータを可視化した。住宅価格がどのように分布しているのかを見るためにヒストグラムを作成した。また住宅価格と関わりがありそうな変数を見るために、各変数と住宅価格との散布図を作成した。次に予測するために幾つかのモデルでパラメータ推定を行った。まずデータをテストデータ 10 個と残りを訓練データとして分けた。そして全ての変数を含む重回帰を行い、次に変数の全ての組み合わせで AIC が最小となるような、モデルを選んだ。最後にラッソ回帰を交差検証で最適なアルファを求め行った。そして各回帰で得られたモデルでテストデータを推定し、二乗誤差を計算し、予測値と実際の値をグラフにまとめた。この二乗誤差がどのモデルでより小さくなっているのかを見て各モデルの良さを確認してみる。人口や所得や築年数が住宅価格に影響があると思われ、ラッソ回帰を行った際には緯度や経度の変数の係数は 0 になると予想する。

3. Results



住宅価格のヒストグラム



【係数の 95%信頼区間】

const	-38.220528	-35.637353
MedInc	0.428264	0.444716
HouseAge	0.008547	0.010297
AveRooms	-0.118539	-0.095467
AveBedrms	0.588414	0.698705
Population	-0.000013	0.000005
AveOccup	-0.004738	-0.002828
Latitude	-0.435488	-0.407276
Longitude	-0.449201	-0.419669

AIC で選ばれた変数: ['MedInc', 'HouseAge', 'AveRooms', 'AveBedrms', 'AveOccup', 'Latitude', 'Longitude']

Lasso 最適 alpha: 0.0042


Lasso で選ばれた変数: ['MedInc', 'HouseAge', 'AveRooms', 'AveBedrms', 'AveOccup', 'Latitude', 'Longitude']

テストデータ(10 個)に対する予測精度比較

重回帰 (全変数): RMSE = 0.9703

AIC 最小モデル : RMSE = 0.9700

Lasso 回帰 : RMSE = 0.9893



4. Discussions

AIC によるモデル選択とラッソ回帰において、8 個の変数のうち唯一人口だけが除外されていた。ここから人口は住宅価格に影響を与えているとはいいにくいということがわかる。重回帰を見ても人口だけ 95%信頼区間に 0 が入っているので、重回帰の場合でもほとんど人口の変数は影響を与えていない。各モデルでのテストデータの予測精度を見ていくと、一番成績が良いのは AIC で次に僅差で重回帰、そしてラッソ回帰になっている。これは AIC モデルでは人口を排除したことで予測に寄与しないと思われるノイズを取り除いたことでわずかながら精度が向上したことが考えられる。また今回は使用したデータ数が多かったため、モデルの複雑さへの罰則項の影響が小さくなり、変数が 7 個という複雑よりであるモデルで AIC が最小となっている。ラッソ回帰は正則項の影響で、訓練データの適合度が小さくなり予測もうまくできなかったものと考えられる。今回使用したデータセットは、サンプル数が多い、それに比べ変数が少なかったため、オーバーフィッティングを防ぐ強力な正則化より不偏推定のほうがより良い結果を出したのだと思われる。実際に重回帰によるテストデータの予測値と信頼区間と本当の値のグラフを見ると、10 個中 9 個が信頼区間の中に入っていて誤差の分散も適切に見積もれていたことがわかる。パラメータの大きさを見ていくと、想像通り所得が強い影響を与えており、また想像に反して緯度経度の立地の変数もかなり影響を与えていることがわかる。

今回使用したデータは 1990 年のカリフォルニアのデータなので、過去の一部分の場所のデータである。他の年代のデータや、より広範囲の場所でのデータがあるとまた別の結果が得られるのかもしれない。また今回は各変数において線形の関係が

あるかどうかを調べていたが、非線形モデルを適応するとより適切に予測を行うことができると考えられる。また今回使用したデータの変数は8個のみだったのでもっと多くの変数のデータを取り解析すると、より詳しく分析ができる。

データの出典

Pace, R. Kelley and Barry, Ronald. "Sparse Spatial Autoregressions," Statistics and Probability Letters, 33(3), 291-297, 1997.