

情報数理科学Ⅲ

Assignment 1: machine learning with features

学際科学科 3 年 南條佑太

学籍番号:08-262024

1. 使用したデータセットについて

今回使用したデータセットは scikit-learn から取得したワインの特徴量に関するものである。特徴量は 13 種類あり、Alcohol、Malic acid、Ash、Alcalinity of ash、Magnesium、Total phenols、Flavanoids、Nonflavanoid phenols、Proanthocyanins、Color intensity、Hue、OD280/OD315 of diluted wines、Proline となっていて全て欠損値が無いデータである。分類の目的変数はどの品種かであり、3 つのカテゴリである。データの数 は 178 個含まれている。このデータセットを使用して、13 の特徴量からどの品種のワインかを分類するようなアルゴリズムを作っていく。

2. 使用したアルゴリズムとその結果

データを訓練データとテストデータに分け、各アルゴリズムについて訓練データで学習させ、その中で最も精度が良かったモデルに対してテストデータを予測させて正解度で精度を確かめた。

2.1 決定木

深さの制限を 2 から 6 と制限なしにして木の深さが大きくなってオーバーフィットしてしまわないようにした。交差検証でそれぞれの深さの木で学習させ最もスコアが高いモデルを採用する。そしてそのモデルでテストデータを予測して正解とのズレで精度を出した。そしてその最も精度が良かった決定木を表示させた。

実際にこのデータセットを学習させたところ、結果は深さが 3 の木が最も精度が良く、テストの正解率は 0.9630 となった。決定木は以下の図 1 のようになった。




図 1 決定木

2.2 ロジスティック回帰

まず全ての特微量を標準化させて、またオーバーフィッティングしてしまわないように、正則化項をつけ足してロジスティック回帰を行った。正則化項をいくつか変化させて、交差検証を同様にを行い最も成績が良かったものを採用して、テストデータを予測し正解率を求めた。そしてその最適なモデルで、それぞれの特微量の係数を図示することでどの特微量が分類により寄与しているかを可視化した。

結果として、最適な正則化のパラメータは 50 で、テストケースの正解率は 0.9815 となった。以下の図 2 が各分類における特微量の係数のグラフである。

2.3 多層パーセプトロン

隠れ層として(50,),(100,),(150,),(50,50)の1層のものを3つ,2層のものを1つ用意して、学習をさせた。個々の学習機は先ほどのロジスティック回帰と同じように設定をして交差検証をして学習をさせた。

結果としては正則化項の係数は 0.0001 で隠れ層は(100,)のものが最も精度が良く、その時のテストデータに対する正解率は 0.9815 となった。

2.4 ランダムフォレスト

4つ目の自由に選ぶアルゴリズムとしてランダムフォレストを選んだ。個々の




図 2 ロジスティック回帰での係数

決定木の深さは 3, 5, None とし、決定木の数 は 50, 100, 200 とし て交差検証で最適なパラメータの組み合わせを探した。そうして同様にテストデータを予測してその正解度を求めた。

最適なモデルは、深さが3で量が50のものになり、その時の正解率は1.000となった。以下の図3にfeature_importances_でどの特徴量が分類に役立ったかの数値を降順に並べたものを記載する。




図3 ランダムフォレストでの特徴量の寄与度合い

3. 比較と考察

まず各アルゴリズムのテストデータに対する正解率を比較する。正解率は決定木が最も低く、次いで多層パーセプトロンとロジスティック回帰が同値となり、ランダムフォレストが最高値（1.000）を記録した。決定木は、最適な最大の深さが3と比較的浅くシンプルな構造であったにもかかわらず、9割を超える高い正解率を示した。これは、本データセットにおけるワインの品種ごとに特徴量の差異が明確であり、単純な条件分岐でも十分に高い精度で分類が可能であったためと考えられる。さらにランダムフォレストでは、単体でも9割超の精度を持つ決定木を複数構築し、アンサンブル学習によって予測を行った。その結果テストデータに対して全問正解という極めて高い汎化性能を発揮した。

一般的にロジスティック回帰と多層パーセプトロンは後者の方の正解率が高くなると予想されるが、今回は正答率が同じであった。その理由として考えられるのは、1つのパーセプトロンで訓練データを完璧に分類できていたので多層で行っても対して分類の方法が変わらなかったのではないかと

思われる。またテストデータの数もあまり多くなかったので、本来は少し差が出ていたがそれが正解率に寄与しなかった可能性がある。

次に正則化項のパラメータについて、両方の場合で正則化項があまり影響しないようにするようなパラメータが選ばれている。これは特徴量に対し、訓練データの数が多いのであまりオーバーフィッティングしなかったためと考えられる。

また、それぞれの方法での最適なモデルで使用されている特徴量を図1、図2、図3から読み取ると、大まかに使用されている特徴量が同じであることがわかる。別々の方法でモデルを作成しても同じような特徴量を基準に分類をしていたことがわかる。